Clustering, matriz de confusión, regresión y sus métricas

Conceptos, fórmulas y ejemplos numéricos
MAE, MSE, RMSE, MAPE y R-cuadrada

Ricardo Hernán Navarrete Vázquez

Ingeniería en Sistemas Computacionales

Instituto Tecnológico de Ciudad Juárez

Ciudad Juárez, Chihuahua | Noviembre de 2026

Contenido

1. ¿Qué es el clustering?

2. ¿Qué es la matriz de confusión?

3. ¿Qué es la regresión?

4. Métricas de regresión: MAE, MSE, RMSE, MAPE y R^2

5. Ejemplo completo calculado paso a paso

6. Comparación y cuál elegir

1. ¿Qué es el clustering?

El **clustering** (agrupamiento) es una técnica de **aprendizaje no supervisado** que agrupa datos según su parecido, **sin que existan etiquetas previas**. El modelo no sabe qué es cada dato; solo descubre qué datos se parecen entre sí y los junta en grupos llamados *clusters*.

Idea clave: los datos dentro de un mismo grupo deben ser lo más parecidos posible entre sí, y los de grupos distintos, lo más diferentes posible.

Ejemplos de uso

• Segmentar clientes de una tienda según lo que compran (clientes frecuentes, ocasionales, de descuentos).

• Agrupar noticias o documentos por tema.

• Detectar zonas con patrones parecidos en un mapa (por ejemplo, zonas con muchos reportes de baches).

• Comprimir imágenes agrupando colores similares.

Algoritmos más comunes

Algoritmo	Cómo funciona	Se necesita definir
K-Means	Coloca k centros, asigna cada punto al centro más cercano y recalcula los centros hasta estabilizarse.	Número de grupos (k)
Clustering jerárquico	Va uniendo (o dividiendo) grupos paso a paso formando un árbol (dendrograma).	Dónde cortar el árbol
DBSCAN	Agrupa zonas densas de puntos y marca como ruido los puntos aislados.	Radio (eps) y mínimo de puntos

Cómo funciona K-Means (el más usado)

1. Elegir k, el número de grupos.

2. Colocar k centroides al azar.

3. Asignar cada punto al centroide más cercano.

4. Recalcular cada centroide como el promedio de los puntos de su grupo.

5. Repetir los pasos 3 y 4 hasta que los grupos ya no cambien.

Cómo saber si el agrupamiento es bueno

Como no hay etiquetas, se usan métricas como el **coeficiente de Silhouette** (de -1 a 1; entre más cerca de 1, mejores grupos), el índice de Davies-Bouldin (más bajo es mejor) y el **método del codo** para elegir k.

Diferencia importante: el clustering **no usa matriz de confusión ni MAE/RMSE**, porque no hay una respuesta correcta contra la cual comparar. Esas métricas son de modelos supervisados (clasificación y regresión).

2. ¿Qué es la matriz de confusión?

La **matriz de confusión** es una tabla que compara lo que el modelo **predijo** contra lo que **realmente era**, en problemas de **clasificación**. Muestra no solo cuántas veces se equivocó, sino **en qué se equivocó**.

Para clasificación binaria (positivo / negativo) tiene 4 casillas:

	Predicho: Positivo	**Predicho: Negativo**
Real: Positivo	**VP** - Verdadero positivo (acertó: era positivo y dijo positivo)	**FN** - Falso negativo (error: era positivo y dijo negativo)
Real: Negativo	**FP** - Falso positivo (error: era negativo y dijo positivo)	**VN** - Verdadero negativo (acertó: era negativo y dijo negativo)

Ejemplo: un modelo que detecta correos spam (positivo = spam)

Se probó con 100 correos: 50 eran spam y 50 no.

	Predicho: Spam	**Predicho: No spam**
Real: Spam (50)	VP = 40	FN = 10
Real: No spam (50)	FP = 5	VN = 45

Métricas que salen de la matriz

Métrica	**Fórmula**	**Resultado del ejemplo**	**Qué responde**
Accuracy	(VP + VN) / total	(40 + 45) / 100 = **0.85**	¿Qué porcentaje acertó en total?
Precision	VP / (VP + FP)	40 / 45 = **0.889**	De lo que dijo que era spam, ¿cuánto sí lo era?
Recall	VP / (VP + FN)	40 / 50 = **0.80**	Del spam real, ¿cuánto logró detectar?

Métrica	Fórmula	Resultado del ejemplo	Qué responde
Especificidad	VN / (VN + FP)	45 / 50 = **0.90**	De lo que no era spam, ¿cuánto identificó bien?
F1-score	2 x P x R / (P + R)	**0.842**	Balance entre precision y recall

Por qué importa: si solo miras accuracy puedes engañarte. Un modelo que dice "no hay fraude" siempre tendría 99% de accuracy si solo 1% de las transacciones son fraude, pero detectaría 0 fraudes. La matriz de confusión lo deja a la vista.

Si hay más de 2 clases, la matriz crece (3x3, 4x4...): las filas son las clases reales, las columnas las predichas, y lo ideal es que los números grandes estén en la diagonal.

3. ¿Qué es la regresión?

La **regresión** es una técnica de **aprendizaje supervisado** que predice un **valor numérico continuo** a partir de otras variables. A diferencia de la clasificación (que responde "¿qué categoría es?"), la regresión responde "**¿cuánto?**".

Ejemplo	Variables de entrada	Qué predice
Precio de una casa	m^2, colonia, recámaras	Precio en pesos
Ventas del mes	Mes, publicidad, temporada	Cantidad vendida
Consumo de luz	Temperatura, hora, día	kWh
Calificación de un alumno	Horas de estudio, asistencia	Calificación final

Tipos comunes

• **Regresión lineal simple:** una variable de entrada. Ajusta una recta: $y = b0 + b1*x$.

• **Regresión lineal múltiple:** varias variables de entrada: $y = b0 + b1*x1 + b2*x2 + ...$

• **Regresión polinomial:** ajusta curvas cuando la relación no es una línea recta.

• **Árboles, Random Forest, redes neuronales:** modelos más flexibles que también sirven para regresión.

En todos los casos el modelo produce una predicción (y_pred) que se compara contra el valor real (y). La diferencia entre ambos es el **error** o **residuo**: *error = y - y_pred*. Las métricas de la siguiente sección resumen esos errores en un solo número.

4. Métricas de regresión

Notación: n = número de datos, y = valor real, y_pred = valor predicho, y_prom = promedio de los valores reales.

4.1 MAE - Error Absoluto Medio

Fórmula: MAE = (1/n) x suma de |y - y_pred|

Es el promedio de los errores sin importar si fueron por arriba o por abajo (se les quita el signo con el valor absoluto). Está en la **misma unidad** que lo que predices: si predices pesos, el MAE son pesos. Un MAE de 900 significa "en promedio me equivoco por 900 pesos". Es fácil de explicar y **no se deja afectar demasiado por valores atípicos**.

4.2 MSE - Error Cuadrático Medio

Fórmula: MSE = (1/n) x suma de $(y - y_pred)^2$

Eleva cada error al cuadrado antes de promediar. Así los **errores grandes se castigan mucho más** que los pequeños (un error de 10 pesa 100, uno de 2 pesa 4). Su desventaja es que queda en **unidades al cuadrado** (pesos al cuadrado), lo que es difícil de interpretar. Es muy usado para entrenar modelos porque es matemáticamente cómodo de optimizar.

4.3 RMSE - Raíz del Error Cuadrático Medio

Fórmula: RMSE = raíz cuadrada de MSE

Es el MSE pero sacándole raíz, así regresa a la **unidad original** y sí se puede interpretar. Conserva la característica de castigar los errores grandes. Siempre se cumple que **RMSE >= MAE**; si el RMSE es mucho mayor que el MAE, significa que hay algunos errores muy grandes mezclados con otros pequeños.

4.4 MAPE - Error Porcentual Absoluto Medio

Fórmula: MAPE = (100/n) x suma de |y - y_pred| / |y|

Expresa el error como **porcentaje del valor real**. Un MAPE de 10% dice "en promedio me equivoco 10% respecto al valor real". Es muy cómodo para explicarle a alguien que no es técnico y para comparar modelos de datos con escalas distintas. **Limitaciones:** no se puede calcular si algún valor real es 0 y se vuelve enorme cuando los valores reales son muy pequeños; además penaliza más cuando el modelo predice de más que de menos.

4.5 R^2 - Coeficiente de determinación

Fórmula: R^2 = 1 - (suma de $(y - y_pred)^2$) / (suma de $(y - y_prom)^2$)

Mide **qué proporción de la variación de los datos logra explicar el modelo**. Compara tu modelo contra uno muy simple que siempre predice el promedio.

Valor de R^2	Interpretación
1	Predicción perfecta.
0.80	El modelo explica el 80% de la variación de los datos.
0	El modelo no es mejor que siempre predecir el promedio.
Negativo	El modelo es peor que predecir el promedio.

Ojo: R^2 no tiene unidades y no dice qué tan grande es el error en términos reales; un R^2 alto no garantiza un buen modelo. Además, agregar variables nunca lo baja, por eso en regresión múltiple se usa el **R^2 ajustado**.

5. Ejemplo completo calculado paso a paso

Un modelo predice las calificaciones de 5 alumnos. Estos son los valores reales y los predichos:

Alum.	Real	Pred.	Error	|Error|	$Error^2$	|Error|/y	$(y\text{-}prom)^2$
1	3	2.5	+0.5	0.5	0.25	0.1667	4.84
2	5	5.0	+0.0	0.0	0.00	0.0000	0.04
3	2	4.0	-2.0	2.0	4.00	1.0000	10.24
4	7	8.0	-1.0	1.0	1.00	0.1429	3.24
5	9	8.0	+1.0	1.0	1.00	0.1111	14.44
Suma	26			**4.5**	**6.25**	**1.4206**	**32.80**

El promedio de los valores reales es y_prom = 26 / 5 = 5.2.

Métrica	Cálculo	Resultado
MAE	4.5 / 5	**0.90**
MSE	6.25 / 5	**1.25**
RMSE	raíz de 1.25	**1.118**
MAPE	(1.4206 / 5) x 100	**28.41%**
R^2	1 - (6.25 / 32.80)	**0.809**

Lectura: el modelo se equivoca en promedio **0.9 puntos** (MAE) y explica cerca del **81%** de la variación (R^2). El MAPE sale alto (28%) sobre todo por el alumno 3: su calificación real era 2 y el modelo predijo 4, un error de 100% en términos relativos. Eso muestra por qué MAPE se infla cuando hay valores reales pequeños.

6. Comparación y cuál elegir

Métrica	Unidad	Castiga errores grandes	Sensible a outliers	Mejor cuando...
MAE	Igual que y	No (trato lineal)	Poco	Quieres un error promedio fácil de explicar
MSE	Unidad al cuadrado	Mucho	Mucho	Entrenar/optimizar el modelo

Métrica	Unidad	Castiga errores grandes	Sensible a outliers	Mejor cuando...
RMSE	Igual que y	Mucho	Mucho	Los errores grandes son especialmente graves
MAPE	Porcentaje	No	Depende (falla con y cercano a 0)	Quieres expresar el error en %
R^2	Sin unidad (0 a 1 típicamente)	Parcialmente	Sí	Quieres saber qué tanto explica el modelo

Recomendación práctica

• Reporta siempre **al menos dos**: por ejemplo MAE (o RMSE) + R^2.

• Si hay outliers que no te importan, usa MAE; si esos errores grandes sí son graves, usa RMSE.

• Usa MAPE solo si los valores reales no están cerca de 0.

• Evalúa siempre con **datos de prueba** (no los de entrenamiento) para que las métricas sean honestas.